

MODELOS SUPERVISADOS AVANZADOS Y APRENDIZAJE NO SUPERVISADO APLICADOS A LA PREDICCIÓN DEL PRECIO DE VIVIENDAS

Informe para la Actividad 2 de la asignatura Aprendizaje Automático

Presentado por: Omar Javier Daza Leguizamón



Fundación Universitaria Internacional de La Rioja
Especialización en Inteligencia Artificial
Septiembre de 2026

Contenido

Introducción.....	3
1. Análisis descriptivo de los datos	3
1.1 Estadísticos de las variables numéricas	4
1.2 Categorías y frecuencias de las variables categóricas	4
1.3 Matriz de correlaciones	5
2. Tratamiento de valores faltantes.....	6
2.1 Inventario de datos faltantes.....	6
2.2 Decisiones adoptadas para el llenado de datos faltantes	7
3. Problema de regresión.....	8
3.1 Partición de datos	8
3.2 Árbol de decisión y efecto de la poda	8
3.3 <i>Random forest</i> y <i>gradient boosting</i>	9
3.3 Red neuronal multicapa	9
3.4 Comparación de los cinco modelos	10
3.5 Ventajas, desventajas y utilidad de los modelos	11
4. Problema de clasificación	12
4.1 Exactitud global y exactitud por grupo	12
4.2 Efecto del kernel y del parámetro de margen	13
4.3 Sugerencias sobre el grupo 3	14
5. Agrupamiento para segmentación	15
5.1 Número de grupos	15
5.2 Perfil de los grupos obtenidos	15
5.3 Correspondencia con los rangos de precio	16
6. Detección de anomalías.....	17
6.1 Aplicación del modelo e identificación de atípicas.....	17
6.2 Relación con el caso de detección de fraude financiero	18
7. Aprendizaje por refuerzo	18
7.1 Entrenamiento del agente	18
7.2 Reflexión sobre RLHF	19
8. Comentarios sobre los resultados	20
Conclusiones	21
Bibliografía	21

Introducción

La estimación del precio de una vivienda es un problema clásico de aprendizaje automático porque se combinan variables de naturaleza muy distinta, como las dimensiones del inmueble, la calidad de los materiales, la antigüedad de la construcción y la ubicación dentro de la ciudad. La disponibilidad de conjuntos de datos públicos y bien documentados permite comparar el desempeño de diferentes familias de algoritmos en un mismo problema, que es el propósito de este laboratorio.

El conjunto de datos utilizado corresponde a las viviendas residenciales vendidas en la ciudad de Ames, estado de Iowa, entre los años 2006 y 2010, compilado a partir de los registros de la oficina de catastro municipal (De Cock, 2011). El archivo `housing_train.csv`, publicado en *Kaggle*, contiene 1.460 registros y 81 columnas, de las cuales 79 son variables explicativas, una es el identificador del registro y una es la variable objetivo *SalePrice*. La actividad entrega también el archivo `housing_test.csv`, con 1.459 registros; sin embargo, este segundo archivo no contiene la columna *SalePrice*, por lo que no permite calcular el error de predicción ni la matriz de confusión. Por esta razón, todo el trabajo se desarrolla sobre `housing_train.csv`, dividido internamente en un conjunto de entrenamiento y uno de prueba. Esta decisión es consistente con las cifras de referencia entregadas en el enunciado, cuyas matrices de confusión suman 292 registros, equivalentes al 20 % de los 1.460 disponibles.

El laboratorio aborda dos problemas sobre el mismo conjunto de datos. El primero es un problema de regresión, en el que se predice el precio de venta y se comparan cinco modelos: árbol de decisión, árbol podado, *random forest*, *gradient boosting* y red neuronal multicapa. El segundo es un problema de clasificación, en el que el precio se divide en tres rangos y se comparan árbol de decisión, *random forest*, *gradient boosting* y máquinas de vector soporte con dos tipos de *kernel*. A estos se suman tres ejercicios complementarios: la segmentación de las viviendas mediante K-means y agrupamiento jerárquico, la detección de viviendas atípicas con *Isolation Forest* y su relación con el caso de detección de fraude financiero, y un ejercicio introductorio de aprendizaje por refuerzo con *Q-learning* que cierra con una reflexión sobre el aprendizaje por refuerzo con retroalimentación humana.

El desarrollo se realizó en Python 3.12 con las librerías *scikit-learn*, *XGBoost*, *TensorFlow/Keras* y *Gymnasium*. Todo el procedimiento, con el código y las salidas completas, se encuentra en el *notebook* `Act2_Housing_UNIR_V1.ipynb` que se adjunta como evidencia. Los numerales de este informe corresponden a las secciones del notebook, de modo que cada resultado presentado aquí puede verificarse en la sección homóloga. Por la restricción de extensión del informe, algunas tablas de detalle se referencian en lugar de reproducirse.

1. Análisis descriptivo de los datos

El conjunto de datos contiene 1.460 registros y 81 columnas, sin filas duplicadas y con un identificador único que abarca los valores de 1 a 1.460. Las ventas corresponden al periodo comprendido entre 2006 y 2010. De las 80 columnas distintas del identificador, 37 son numéricas, incluida la variable objetivo, y 43 son categóricas. Esta composición condiciona la selección de los algoritmos, ya que más de la mitad de la

información es de tipo cualitativo y los modelos basados en árboles manejan este tipo de variables con mayor facilidad que los modelos lineales.

1.1 Estadísticos de las variables numéricas

La variable objetivo presenta un valor mínimo de 34.900 dólares y un máximo de 755.000 dólares, con una mediana de 163.000 y una media de 180.921. La diferencia entre ambas medidas de tendencia central indica que un grupo reducido de viviendas de precio elevado desplaza la media hacia arriba. El coeficiente de asimetría es de 1,883, y desciende a 0,121 al aplicar la transformación logarítmica, lo que confirma la asimetría positiva de la distribución (Figura 1). Esta característica es relevante para la red neuronal, que se beneficia de una variable objetivo simétrica, mientras que los modelos basados en árboles no se ven afectados porque son invariantes a transformaciones monótonas.




Figura 1. Distribución del precio de venta en escala original y logarítmica.

Con 1.460 observaciones y 79 variables explicativas, la relación entre el número de registros y el número de predictores es de aproximadamente 18 a 1, suficiente para ajustar modelos basados en árboles pero limitada para arquitecturas de aprendizaje profundo, que requieren volúmenes de datos considerablemente mayores. Para el caso del análisis presentado en este informe (numeral 3), en donde se tiene una red neuronal con 46.337 parámetros ajustables que se entrena con 1.168 registros, se tienen unos 40 parámetros por observación disponible; lo cual resulta insuficiente para sacar el máximo de provecho del modelo.

El análisis de los estadísticos descriptivos también permite responder la pregunta sobre la eliminación de variables. Ocho variables numéricas presentan el valor cero en más del 85 % de los registros, entre ellas *PoolArea* con 99,5 %, *LowQualFinSF* con 98,2 %, *3SsnPorch* con 98,4 % y *MiscVal* con 96,4 %. Estas variables aportan poca información discriminante y pueden eliminarse o transformarse en variables binarias que indiquen únicamente la presencia o ausencia de la característica. La tabla completa de estadísticos descriptivos se encuentra en la sección 1.2 del *notebook*.

1.2 Categorías y frecuencias de las variables categóricas

Las 43 variables categóricas presentan entre 2 y 25 categorías. La de mayor número de niveles es *Neighborhood*, con 25 barrios, donde el más frecuente es *North Ames* con 225 viviendas, equivalentes al 15,4 % del total. En el extremo opuesto se encuentran variables con una categoría dominante que

concentra casi todos los registros, como *Utilities*, donde el nivel *AllPub* reúne 1.459 de las 1.460 viviendas, y *Street*, donde el nivel *Pave* reúne 1.454. Estas variables, al igual que las numéricas con mayoría de ceros, son candidatas a eliminarse porque no permiten distinguir entre observaciones. El listado completo de categorías y frecuencias para las 43 variables se presenta en la sección 1.3 del notebook.

1.3 Matriz de correlaciones

La matriz de correlaciones se construyó con el coeficiente de Pearson sobre las 37 variables numéricas. Las variables más asociadas con el precio de venta son la calidad general de los materiales y acabados, y el área habitable sobre el nivel del suelo (Tabla 1 y Figura 2). Las correlaciones negativas son débiles en todos los casos, con un valor mínimo de -0,136 para el número de cocinas. La matriz de correlación completa se puede revisar en el numeral 1.3 del *notebook*.

Tabla 1. Variables numéricas con mayor correlación con el precio de venta.

Variable	Descripción	Correlación
<i>OverallQual</i>	Calidad general de materiales y acabados	0,791
<i>GrLivArea</i>	Área habitable sobre el nivel del suelo	0,709
<i>GarageCars</i>	Capacidad del garaje en número de vehículos	0,640
<i>GarageArea</i>	Área del garaje	0,623
<i>TotalBsmtSF</i>	Área total del sótano	0,614
<i>1stFlrSF</i>	Área del primer piso	0,606
<i>FullBath</i>	Baños completos sobre el nivel del suelo	0,561
<i>TotRmsAbvGrd</i>	Número total de habitaciones	0,534




Figura 2. Quince variables numéricas con mayor correlación con el precio de venta.

En cuanto a la posibilidad de eliminar columnas, el análisis identificó cuatro pares de variables explicativas cuya correlación entre sí es superior a 0,70 (Tabla 2). Cuando dos predictores están fuertemente correlacionados aportan información redundante al modelo, por lo que puede conservarse únicamente

aquel que presenta mayor correlación con la variable objetivo. Bajo este criterio se conservarían *GarageCars*, *YearBuilt*, *GrLivArea* y cualquiera de las dos variables del cuarto par, ya que ambas presentan la misma correlación con el precio. Debe advertirse que los modelos basados en árboles son poco sensibles a la redundancia entre predictores, de modo que la eliminación tiene más efecto sobre la interpretación del modelo que sobre su capacidad predictiva.

Tabla 2. Pares de variables explicativas con correlación superior a 0,70.

Variable A	Variable B	Correlación A-B	Corr. A con precio	Corr. B con precio
<i>GarageCars</i>	<i>GarageArea</i>	0,882	0,64	0,62
<i>YearBuilt</i>	<i>GarageYrBlt</i>	0,826	0,52	0,49
<i>GrLivArea</i>	<i>TotRmsAbvGrd</i>	0,825	0,71	0,53
<i>TotalBsmtSF</i>	<i>1stFlrSF</i>	0,820	0,61	0,61

2. Tratamiento de valores faltantes

2.1 Inventario de datos faltantes

El conjunto de datos presenta valores faltantes en 19 de las 81 columnas, que suman 6.965 celdas vacías (Figura 3). La Figura 4 del documento, que tiene las instrucciones para esta actividad, presenta seis bloques de variables; las cinco columnas con mayor proporción de ausencias no aparecen en ella y corresponden a *PoolQC* con 99,5 %, *MiscFeature* con 96,3 %, *Alley* con 93,8 %, *Fence* con 80,8 % y *FireplaceQu* con 47,3 %. El análisis de esta situación se amplía con las decisiones que se toman en la sección siguiente.




Figura 3. Columnas con valores faltantes y su porcentaje sobre el total de registros.

La decisión sobre cómo llenar los valores faltantes requiere distinguir previamente entre dos situaciones diferentes. En el primer caso el dato existe en la realidad pero no fue registrado, como ocurre con *LotFrontage*, ya que toda vivienda tiene una fachada; aquí corresponde llenar el vacío con un estadístico de la variable. En el segundo caso la ausencia indica que la vivienda no posee la característica, como ocurre

con *BsmtQual* en una casa sin sótano; en esta situación el valor faltante es información y debe convertirse en una categoría propia, porque llenarlo con la moda equivaldría a atribuirle a la vivienda un sótano inexistente.

Esta interpretación no es una suposición del análisis, sino que está documentada por el autor del conjunto de datos. El diccionario de variables (De Cock, 2011) declara de forma explícita el significado del valor NA en cada una de estas columnas: en *PoolQC* corresponde a la ausencia de piscina, en *BsmtQual* a la ausencia de sótano, en *GarageType* a la ausencia de garaje, en *FireplaceQu* a la ausencia de chimenea, en *Fence* a la ausencia de cerca y en *Alley* a la ausencia de callejón de acceso.

La interpretación se verificó además sobre los datos, comparando cada variable cualitativa con su correspondiente variable de área o de conteo. La correspondencia se cumple en el 100 % de los casos: las 1.453 viviendas sin dato en *PoolQC* registran un área de piscina igual a cero, las 690 sin dato en *FireplaceQu* registran cero chimeneas, las 37 sin dato en *BsmtQual* registran un área de sótano igual a cero y las 81 sin dato en *GarageType* registran un área de garaje igual a cero.

2.2 Decisiones adoptadas para el llenado de datos faltantes

Con base en lo anterior se adoptaron tres tipos de tratamiento, resumidos en la Tabla 3. En ningún caso se eliminaron registros, ya que hacerlo habría reducido el conjunto de 1.460 a menos de 500 observaciones, con una pérdida de información desproporcionada frente al problema que se busca resolver.

Tabla 3. Tratamiento aplicado a las columnas con valores faltantes.

Columnas	Faltantes	Tratamiento	Justificación
<i>PoolQC</i> , <i>MiscFeature</i> , <i>Alley</i> , <i>Fence</i> , <i>FireplaceQu</i>	1.453 a 690	Nueva categoría	El valor NA significa que la vivienda no tiene la característica
<i>BsmtQual</i> , <i>BsmtCond</i> , <i>BsmtExposure</i> , <i>BsmtFinType1</i> , <i>BsmtFinType2</i>	37 a 38	Categoría SinSotano	Las 37 viviendas registran área de sótano igual a cero
<i>GarageType</i> , <i>GarageFinish</i> , <i>GarageQual</i> , <i>GarageCond</i>	81	Categoría SinGaraje	Las 81 viviendas registran área de garaje igual a cero
<i>GarageYrBlt</i>	81	Año de construcción de la vivienda	Son viviendas sin garaje; se usa un dato de la misma fila
<i>MasVnrArea</i>	8	Valor cero	La mediana y ambos cuartiles de la variable son cero
<i>MasVnrType</i>	8	Categoría None	Categoría ya existente en la variable, con 864 registros
<i>LotFrontage</i>	259	Mediana	El dato existe en la realidad pero no fue registrado
<i>Electrical</i>	1	Moda	El dato existe; la moda <i>SBrkr</i> cubre 1.334 registros

Las dos últimas decisiones requieren un estadístico calculado sobre los datos, por lo que no se aplicaron sobre el conjunto completo sino dentro del proceso de entrenamiento, utilizando únicamente el

subconjunto de entrenamiento para calcular la mediana y la moda. Si estos estadísticos se calcularan antes de separar los datos, el conjunto de prueba habría contribuido a definir los valores usados para entrenar y la evaluación resultaría optimista. Las demás decisiones no dependen de ningún estadístico muestral y pueden aplicarse antes de la partición.

Un aspecto técnico relevante para la reproducibilidad es la lectura del archivo. La configuración predeterminada de la librería *Pandas* interpreta la cadena *None* como valor nulo, y en este conjunto de datos *None* es una categoría legítima de *MasVnrType* que agrupa 864 viviendas sin revestimiento de mampostería. Al leer con esa configuración se obtienen 872 faltantes en esa columna en lugar de los 8 reales. La lectura se realizó declarando explícitamente que únicamente la cadena *NA* representa ausencia, con lo cual las cifras coinciden con las de la Figura 4 del documento con las instrucciones para la actividad. Tras aplicar los tratamientos descritos, el número de celdas faltantes se reduce de 6.965 a 260, correspondientes a las dos columnas que se llenan durante el entrenamiento.

3. Problema de regresión

3.1 Partición de datos

Los datos se dividieron en un conjunto de entrenamiento con 1.168 registros y uno de prueba con 292, que corresponden al 80 % y al 20 % del total. La partición se estratificó según el rango de precio para garantizar que las tres categorías definidas en el numeral 4 conserven su proporción en ambos conjuntos, y se utilizó la misma partición en todos los modelos de los numerales 3 y 4, de modo que las comparaciones sean válidas. La métrica principal es la raíz del error cuadrático medio (RMSE) sobre el conjunto de prueba, cuyo precio promedio es de 181.978 dólares.

3.2 Árbol de decisión y efecto de la poda

El árbol de decisión sin restricciones alcanzó una profundidad de 25 niveles y generó 1.133 hojas para 1.168 registros de entrenamiento, es decir, prácticamente una hoja por observación. Su error sobre el conjunto de entrenamiento es exactamente cero, lo que constituye la evidencia más directa de sobreajuste: el modelo memorizó los datos con los que fue construido. Sobre el conjunto de prueba, en cambio, el RMSE es de 38.816,5 dólares.

La poda se realizó mediante el método de complejidad de coste, que penaliza el número de hojas del árbol a través de un parámetro de ajuste. El valor de dicho parámetro se seleccionó por validación cruzada de cinco particiones dentro del conjunto de entrenamiento, sin intervención del conjunto de prueba (Figura 4). El árbol podado conserva 70 hojas de las 1.133 originales y reduce el RMSE a 37.226,8 dólares.




Figura 4. Selección del nivel de poda mediante validación cruzada.

Este resultado difiere del reportado en el documento con las instrucciones de la actividad, en el cual el RMSE aumentó de 41.002,2 a 42.927,25 después de podar. La diferencia no debe interpretarse como la invalidación de ninguno de los dos resultados, sino que muestra que el efecto de la poda depende de cómo se elige el nivel de simplificación. Cuando ese nivel se selecciona por validación cruzada, la poda elimina las divisiones que responden al ruido de los datos de entrenamiento y mejora la generalización; cuando se fija sin validar, puede eliminar divisiones útiles y deteriorar el desempeño. La conclusión general que se desprende es que un árbol individual, podado o sin podar, presenta una capacidad predictiva limitada sobre este conjunto de datos.

3.3 Random forest y gradient boosting

El *random forest*, construido con 500 árboles, redujo el RMSE a 29.615,4 dólares, lo que representa una mejora del 23,7 % respecto del árbol sin podar. La explicación de esta diferencia está en el mecanismo del algoritmo, en el que cada árbol se entrena sobre una muestra distinta obtenida por remuestreo y en cada división considera solo un subconjunto aleatorio de predictores, de modo que los árboles resultan poco parecidos entre sí. Al promediar sus predicciones, los errores particulares de cada árbol tienden a compensarse y la varianza del conjunto disminuye. Un árbol individual, en cambio, concentra toda la predicción en una única estructura que depende fuertemente de los datos con los que fue construida.

El modelo de *gradient boosting*, implementado con la librería *XGBoost*, obtuvo el mejor resultado con un RMSE de 24.304,6 dólares. A diferencia del *random forest*, que promedia árboles independientes, el *boosting* los construye de forma secuencial: cada árbol nuevo se ajusta sobre los errores que dejó el conjunto anterior. El entrenamiento se detuvo automáticamente en el árbol 337 de un máximo de 1.000, al no registrarse mejoras durante 50 rondas consecutivas.

3.3 Red neuronal multicapa

La red neuronal se construyó con la librería *Keras* y está compuesta por una capa de entrada con 296 variables, resultado de codificar las variables categóricas, dos capas ocultas densas de 128 y 64 neuronas con función de activación *ReLU*, una capa de regularización por abandono del 20 % entre ellas y una

neurona de salida con activación lineal, apropiada para un problema de regresión. El modelo tiene 46.337 parámetros ajustables.

El entrenamiento se realizó con el optimizador *Adam* y una tasa de aprendizaje de 0,001, utilizando el error cuadrático medio como función de pérdida. El ajuste de los pesos se efectúa mediante retropropagación: en cada lote de datos se calcula el error de salida, se propaga hacia atrás por la red aplicando la regla de la cadena para obtener la contribución de cada peso al error total, y los pesos se modifican en la dirección opuesta al gradiente. Se reservó el 20 % del conjunto de entrenamiento para validación y se aplicó detención temprana, que interrumpió el proceso en la época 38 y restauró los pesos de la mejor época (Figura 5). La variable objetivo se transformó con logaritmo y se estandarizó antes del entrenamiento, y las predicciones se convirtieron nuevamente a dólares para que el RMSE resultara comparable con el de los demás modelos. El RMSE obtenido fue de 27.236,3 dólares.




Figura 5. Curva de aprendizaje de la red neuronal multicapa.

3.4 Comparación de los cinco modelos

La Tabla 4 presenta el desempeño de los cinco modelos sobre el mismo conjunto de prueba. Además del RMSE se incluyen el error absoluto medio (MAE), menos sensible a los errores grandes, y el coeficiente de determinación, que indica la proporción de la variabilidad del precio explicada por el modelo.

Tabla 4. Capacidad predictiva de los cinco modelos de regresión.

Modelo	RMSE (USD)	MAE (USD)	R ²	RMSE / precio medio
<i>XGBoost</i>	24.304,6	15.469,2	0,909	13,4 %
Red neuronal (MLP)	27.236,3	17.732,8	0,886	15,0 %
<i>Random forest</i>	29.615,4	18.807,7	0,865	16,3 %
Árbol podado	37.226,8	25.804,7	0,786	20,5 %
Árbol sin podar	38.816,5	26.432,4	0,768	21,3 %




Figura 6. Comparación del RMSE de los cinco modelos sobre el conjunto de prueba.

El orden de desempeño confirma la progresión esperada: el árbol individual es el modelo más débil, el ensamble por promedio mejora de forma sustancial y el ensamble secuencial obtiene el mejor resultado. La red neuronal se ubica en una posición intermedia, por encima del *random forest* pero por debajo del *boosting*, resultado consistente con la observación de que en conjuntos de datos tabulares de tamaño moderado los métodos basados en árboles suelen superar a las redes profundas.

Las reglas prácticas de dimensionamiento para redes neuronales sugieren una proporción contraria a la que se tiene para este caso (18 a 1, como se presentó en el numeral 1.1). A partir de las cotas establecidas por Baum y Haussler (1989), el error de generalización esperado es aproximadamente igual al cociente entre el número de pesos y el número de ejemplos de entrenamiento, de modo que admitir un error del 10 % exigiría cerca de diez observaciones por parámetro, es decir, un conjunto varios órdenes de magnitud mayor que el disponible para el conjunto de datos de este informe. Esta relación es un criterio orientativo y no una ley, ya que las técnicas de regularización permiten entrenar redes que la superan, pero explica por qué la red requirió abandono y detención temprana para no memorizar el conjunto de entrenamiento.

Respecto de las cifras del enunciado en el documento con las instrucciones de la actividad, los valores obtenidos son inferiores en todos los casos (Tabla 5). La diferencia se explica por el cambio de implementación, de semilla aleatoria y de tratamiento de los valores faltantes, ya que las cifras de referencia se obtuvieron en el lenguaje R. Lo relevante es que la conclusión se mantiene: el *random forest* mejora al árbol individual en un 32,7 % según las cifras del enunciado y en un 23,7 % en este informe.

Tabla 5. Contraste entre las cifras del enunciado y los resultados obtenidos.

Modelo	RMSE enunciado (R)	RMSE obtenido (Python)	Diferencia
Árbol sin podar	41.002,2	38.816,5	-5,3 %
Árbol podado	42.927,3	37.226,8	-13,3 %
Random forest	27.588,9	29.615,4	+7,3 %

3.5 Ventajas, desventajas y utilidad de los modelos

El árbol de decisión ofrece como principal ventaja su interpretabilidad, ya que la secuencia de decisiones puede leerse directamente y explicarse a una persona sin formación técnica, y no requiere estandarizar

las variables. Su desventaja es la inestabilidad porque para pequeños cambios en los datos de entrenamiento producen estructuras distintas, y sin poda memoriza el conjunto de entrenamiento. El *random forest* corrige esa inestabilidad y entrega un desempeño notablemente superior, a costa de perder la interpretación directa, ya que el resultado proviene del promedio de 500 estructuras. El *gradient boosting* alcanza la mayor precisión, pero requiere ajustar más parámetros y es más susceptible al sobreajuste si no se controla el punto de detención del entrenamiento. La red neuronal es el modelo más flexible, de todos los utilizados, en cuanto a las relaciones que puede representar, aunque requiere estandarización de las variables, transformación de la variable objetivo y un tiempo de entrenamiento mucho mayor, sin obtener a cambio el mejor resultado para el análisis de datos en este informe.

En cuanto a la utilidad práctica de los modelos, se encontró que el mejor RMSE obtenido corresponde al 13,4 % del precio promedio de las viviendas del conjunto de prueba. Para una vivienda de precio medio, el error típico de la estimación sería de aproximadamente 24.300 dólares. Este resultado es razonable para un uso orientativo, es decir, como una estimación preliminar para un comprador o una primera aproximación al valor de un inmueble, pero no podría utilizarse para una tasación formal, caso en el cual, se requiere una precisión mayor. La conclusión es que los modelos son útiles como herramienta de apoyo a la toma de decisiones y no como un sustituto de un avalúo hecho por un profesional.

4. Problema de clasificación

Para abordar el problema de clasificación, el precio fue dividido en tres categorías. La primera, grupo1, para precios iguales o inferiores a 100.000 dólares; la segunda, grupo2, para precios entre 100.001 y 500.000; la tercera, grupo3, para precios iguales o superiores a 500.001. En el documento aportado para este informe, se presentan dos redacciones ligeramente distintas para estos límites. Para verificar la consistencia de los resultados, en el marco de las instrucciones de la actividad, se verificó que ninguna vivienda del conjunto de datos se ubica en los intervalos donde ambas difieren, por lo que las dos producen exactamente la misma partición.

La distribución resultante está desbalanceada con 123 viviendas en el grupo1, 1.328 en el grupo2 y tan solo 9 en el grupo3 (equivalente al 0,6 % del total). En el conjunto de prueba esta proporción produce 25, 265 y 2 registros respectivamente, valores que coinciden con las de las matrices de confusión del documento guía. La variable *SalePrice* se excluyó de los predictores, ya que la categoría se deriva de ella y su inclusión produciría una exactitud artificial del 100 %.

4.1 Exactitud global y exactitud por grupo

El desbalance descrito obliga a interpretar con cuidado la exactitud global. Dado que el 91 % de las viviendas pertenece al grupo2, un clasificador que asignara siempre esa categoría alcanzaría una exactitud global superior al 90 % sin haber aprendido nada. Por esta razón se reporta también la exactitud balanceada, que promedia por igual la exactitud de los tres grupos y penaliza a los modelos que ignoran las categorías minoritarias. Los resultados de los clasificadores evaluados se presentan en la Tabla 6 y las matrices de confusión en la Figura 7.

Tabla 6. Exactitud global, balanceada y por grupo de los clasificadores evaluados.

Modelo	Global	Balanceada	Grupo 1	Grupo 2	Grupo 3
Árbol de decisión	0,921	0,580	80,0 %	94,0 %	0,0 %
Árbol con ponderación de clases	0,925	0,698	64,0 %	95,5 %	50,0 %
<i>Random forest</i>	0,935	0,476	44,0 %	98,9 %	0,0 %
<i>Random forest</i> con ponderación	0,945	0,492	48,0 %	99,6 %	0,0 %
<i>XGBoost</i>	0,952	0,579	76,0 %	97,7 %	0,0 %
SVM kernel lineal	0,918	0,768	88,0 %	92,5 %	50,0 %
SVM kernel RBF	0,928	0,619	92,0 %	93,6 %	0,0 %




Figura 7. Matrices de confusión sobre el conjunto de prueba de 292 registros.

La comparación entre el árbol de decisión y el random forest arroja un resultado que merece atención. En la exactitud global el random forest es superior, con 0,935 frente a 0,921, pero al examinar el detalle por grupo se observa que su desempeño sobre el grupo1 cae del 80 % al 44 %. El ensamble gana exactitud global porque acierta casi la totalidad del grupo2, que es la categoría mayoritaria, y lo hace a costa de la categoría pequeña. La exactitud balanceada refleja esta situación con claridad: 0,476 para el *random forest* frente a 0,580 para el árbol. Este comportamiento difiere del reportado en el enunciado del documento guía, donde el *random forest* mejoraba al árbol en los tres grupos, y muestra que la superioridad de los ensambles observada en el problema de regresión no se traslada automáticamente a un problema de clasificación con clases desbalanceadas.

Entre los modelos evaluados, *XGBoost* obtuvo la mayor exactitud global con 0,952, mientras que la máquina de vector soporte con kernel lineal obtuvo la mayor exactitud balanceada con 0,768, al ser el único modelo que mantiene simultáneamente un buen desempeño en el grupo1, con 88 %, y algún acierto en el grupo3.

4.2 Efecto del kernel y del parámetro de margen

Las máquinas de vector soporte se entrenaron con kernel lineal y con kernel de base radial, evaluando cinco valores del parámetro de margen C. Este parámetro regula el equilibrio entre un margen amplio y la tolerancia a errores de clasificación: un valor bajo admite más observaciones mal clasificadas a cambio de una frontera más suave, mientras que un valor alto exige clasificar correctamente casi todo el conjunto de entrenamiento, con mayor riesgo de sobreajuste. Los resultados se presentan en la Tabla 7 y en la Figura 8.

Tabla 7. Efecto del parámetro C sobre el desempeño de las máquinas de vector soporte.

Kernel	C = 0,01	C = 0,1	C = 1	C = 10	C = 100
Lineal — exactitud global	0,890	0,890	0,918	0,932	0,925
Lineal — exactitud balanceada	0,782	0,770	0,768	0,773	0,759
RBF — exactitud global	0,418	0,839	0,928	0,955	0,962
RBF — exactitud balanceada	0,786	0,775	0,619	0,605	0,595




Figura 8. Efecto del parámetro C sobre la exactitud global y la exactitud balanceada.

El kernel lineal muestra un comportamiento estable en todo el rango evaluado, con variaciones inferiores a cinco puntos porcentuales en ambas métricas. El kernel de base radial, en cambio, es mucho más sensible al valor de C y evidencia con claridad el compromiso entre las dos métricas. Con C igual a 100 alcanza la mayor exactitud global de todo el informe (0,962), pero su exactitud balanceada es de apenas 0,595 y no acierta ningún caso del grupo3. Por otro lado, con C igual a 0,01 ocurre lo contrario: la exactitud global se desploma a 0,418, mientras que la balanceada sube a 0,786 y el grupo3 se identifica en su totalidad. Se trata del mismo algoritmo con el mismo conjunto de datos, y la elección del valor del parámetro determina cuál de los dos objetivos se privilegia.

4.3 Sugerencias sobre el grupo 3

El grupo3 contiene 9 viviendas en todo el conjunto de datos y 2 en la partición de prueba. Esta última cifra impone una limitación que ningún algoritmo puede superar, por lo que la exactitud sobre ese grupo solo puede tomar los valores 0 %, 50 % o 100 %; de modo que cualquier conclusión estadística sobre su desempeño carece de sustento suficiente. Los modelos entrenados sin ninguna corrección no identificaron ningún caso del grupo3, lo cual es esperable porque ignorar una categoría tan pequeña (0,6 % de los datos) apenas afecta el error total que el algoritmo intenta minimizar.

Se evaluó como alternativa la ponderación de clases, que asigna a cada observación un peso inversamente proporcional a la frecuencia de su categoría, de manera que un error sobre una vivienda del grupo3 tenga un costo mucho mayor que uno sobre el grupo2. Aplicada al árbol de decisión, esta corrección elevó la exactitud del grupo3 del 0 % al 50 % y la exactitud balanceada de 0,580 a 0,698, con una reducción en el grupo1 del 80 % al 64 %. Se confirma así que el tratamiento del desbalance no es gratuito y que mejorar la detección de la categoría minoritaria implica ceder desempeño en las demás.

Más allá del ajuste algorítmico, se pueden presentar tres alternativas que dependerán del objetivo del análisis. La primera es unir los grupo3 y grupo2, entendiendo que la frontera de 500.000 dólares deja una categoría demasiado pequeña para ser modelada. La segunda es modificar los límites de los rangos

utilizando los cuantiles, logrando así que las tres categorías tengan tamaños comparables. La tercera es conservar el grupo3 como una categoría de revisión manual y no de predicción automática, tratando las viviendas de precio muy alto como casos excepcionales que requieren valoración individual, en línea con lo que se desarrolla en el numeral 6 de este informe.

5. Agrupamiento para segmentación

El agrupamiento se aplicó a las 36 variables numéricas que describen el inmueble; se excluyó el precio de venta para que la comparación posterior con los rangos de precio no resultara circular. Considerando que los algoritmos utilizados se basan en distancias, fue necesario estandarizar, esto porque, por ejemplo, una variable medida en miles de pies cuadrados dominaría el resultado. Se utilizaron los 1.460 registros, considerando que en un procedimiento no supervisado no existe una variable objetivo que predecir. Además, es importante aclarar que, aunque el enunciado de la guía de la actividad se refiere a la segmentación de clientes, las variables disponibles describen la vivienda y no al comprador, por lo que los grupos se interpretan como perfiles de inmueble.

5.1 Número de grupos

El número de grupos se evaluó mediante el método del codo y el índice de silueta para valores de K entre 2 y 10 (véase la Figura 9). Con esto se tiene que la curva de inercia desciende de manera continua sin presentar un cambio nítido, mientras que el índice de silueta presenta su valor máximo en $K = 2$ (0,148), manteniéndose por debajo de 0,15 en todo el rango. Estos valores indican una estructura de grupos débil, lo que significa que las viviendas forman un continuo antes que conglomerados claramente separados. Con base en lo anterior, se decide adoptar un valor de K igual a 3 como decisión de diseño, con el objetivo de comparar los grupos obtenidos con los tres rangos de precio definidos en el numeral 4.




Figura 9. Método del codo e índice de silueta para la selección del número de grupos.

5.2 Perfil de los grupos obtenidos

Los tres grupos obtenidos mediante *K-means* presentan perfiles bien diferenciados (Tabla 8). Mientras que el grupo 2 reúne 697 viviendas de menor calidad, menor superficie y mayor antigüedad, con un precio promedio de 127.736 dólares, los grupos 0 y 1 corresponden a viviendas de calidad y precio similares entre sí, pero se distinguen por su configuración. El grupo 0 agrupa viviendas con mayor área habitable y un sótano reducido, y el grupo 1 agrupa viviendas con menor área habitable y un sótano amplio, ubicadas sobre lotes de mayor tamaño. En términos prácticos, el algoritmo separó las viviendas económicas y

antiguas de las viviendas amplias y recientes, y, entre estas últimas, las dividió según si el espacio se distribuye en altura o en el sótano.

Tabla 8. Perfil promedio de los grupos obtenidos con K-means.

Grupo	Viviendas	Calidad general	Área habitable	Área sótano	Año construcción	Precio promedio
0	394	6,9	2.009	964	1986	226.960
1	369	7,1	1.623	1.550	1993	232.224
2	697	5,1	1.179	850	1952	127.736

El agrupamiento jerárquico con enlace de *Ward* produjo tres conglomerados de 833, 332 y 295 viviendas. Ambos métodos identifican una estructura similar, aunque con fronteras distintas, lo cual es coherente con la baja separación entre grupos detectada por el índice de silueta.

5.3 Correspondencia con los rangos de precio

La comparación entre los grupos obtenidos y los rangos de precio muestra una coincidencia parcial (Tabla 9 y Figura 10). El grupo 2 de *K-means* concentra 121 de las 123 viviendas del grupo1 de precio, es decir, el segmento económico queda bien identificado sin haber utilizado el precio como variable de entrada. En cambio, las 1.328 viviendas del grupo2 de precio se reparten entre los tres conglomerados, y las 9 viviendas del grupo3 se distribuyen entre los grupos 0 y 1 sin formar un conglomerado propio.

Tabla 9. Distribución de las viviendas entre los grupos de K-means y los rangos de precio.

Grupo K-means	grupo1 (≤ 100.000)	grupo2 (100.001 a 500.000)	grupo3 (≥ 500.001)	Total
0	1	387	6	394
1	1	365	3	369
2	121	576	0	697




Figura 10. Correspondencia entre los grupos obtenidos y los rangos de precio.

La conclusión es que los grupos obtenidos sin supervisión no reproducen los rangos iniciales de precio, excepto para el segmento económico. Esto no se considera una deficiencia del procedimiento, sino que es un hallazgo, porque las características físicas del inmueble estructuran los datos según un eje de tamaño y configuración que se relaciona con el precio, pero no lo determina. Factores como la ubicación, el estado de conservación o las condiciones de la venta influyen en el precio final y no quedan capturados por las variables numéricas empleadas en el agrupamiento inicial.

6. Detección de anomalías

El algoritmo *Isolation Forest* construye árboles mediante divisiones aleatorias y mide cuántas divisiones se requieren para aislar cada observación de las demás. Las observaciones atípicas se aíslan con pocas divisiones, precisamente porque se parecen poco a las demás. El procedimiento no requiere etiquetas previas, es decir, no se le indica al modelo cuáles viviendas son atípicas. Se aplicó sobre la misma matriz de variables numéricas empleada en el agrupamiento, que excluye el precio de venta, con una proporción esperada de anomalías del 2 %.

6.1 Aplicación del modelo e identificación de atípicas

El modelo identificó 30 viviendas atípicas de las 1.460 del conjunto de datos. El contraste con los rangos de precio, que no intervinieron en el análisis, resulta revelador: el 77,8 % de las viviendas del grupo3 fue marcado como atípico, frente a solo el 1,7 % de las viviendas del grupo2. El algoritmo identificó las propiedades de precio excepcional a partir únicamente de sus características físicas. En la Figura 11 se observa que las viviendas señaladas se ubican en los extremos de área habitable y precio.




Figura 11. Viviendas atípicas detectadas sin utilizar el precio como variable de entrada.

Las viviendas más atípicas según el puntaje del modelo se presentan en la Tabla 10. Los dos primeros registros ilustran situaciones distintas. La vivienda 1299 tiene 5.642 pies cuadrados de área habitable, la máxima del conjunto, calidad general de 10 y piscina, pero se vendió en 160.000 dólares, un valor muy inferior al que sugieren sus características; se trata de una venta bajo la condición *Partial*, es decir, de una construcción no terminada al momento de la valoración. La vivienda 692, en cambio, corresponde a una propiedad de lujo vendida en 755.000 dólares, el precio más alto del conjunto, en una operación normal. Conviene señalar que De Cock (2011) advierte en la documentación del conjunto de datos que cinco observaciones con más de 4.000 pies cuadrados de área habitable distorsionan los modelos y recomienda excluirlas; el algoritmo identificó esas mismas observaciones sin conocer dicha recomendación.

Tabla 10. Viviendas con mayor puntaje de anomalía.

Id	Precio	Rango	Área habitable	Área lote	Calidad	Área piscina	Año
1299	160.000	grupo2	5.642	63.887	10	480	2008

Id	Precio	Rango	Área habitable	Área lote	Calidad	Área piscina	Año
692	755.000	grupo3	4.316	21.535	10	0	1994
198	235.000	grupo2	3.112	25.419	8	512	1918
186	475.000	grupo2	3.608	22.950	10	0	1892
524	184.750	grupo2	4.676	40.094	10	0	2007
636	200.000	grupo2	3.395	10.896	6	0	1914

6.2 Relación con el caso de detección de fraude financiero

La lógica aplicada en este ejercicio es la misma que la del caso de detección de fraude financiero estudiado en el curso y trabajado en la primera entrega. En ambas situaciones no se dispone de una definición previa de lo que constituye un caso irregular, y además, el volumen de registros hace inviable la revisión manual de la totalidad de los datos. En consecuencia, el modelo empleado no clasifica casos en legítimos e ilegítimos, sino que señala aquellos cuyo comportamiento se aparta del patrón mayoritario.

La diferencia está en la interpretación del resultado para las dos situaciones. En el contexto financiero, una transacción aislada del patrón habitual sugiere una operación fraudulenta, mientras que, en el contexto inmobiliario, una vivienda aislada puede corresponder a una propiedad de lujo legítima, a un error en el registro catastral o a una tasación que no refleja el valor real del inmueble (lo cual equivaldría a un fraude en este ámbito). En ambos casos, el resultado del modelo no constituye una conclusión sino una priorización, es decir, una lista reducida de casos que un analista debe revisar. Esta es la principal ventaja del enfoque, ya que reduce 1.460 registros a 30 casos de revisión, y también su principal limitación, ya que la decisión final sigue requiriendo criterio humano.

7. Aprendizaje por refuerzo

El ejercicio de aprendizaje por refuerzo se desarrolló en el entorno *FrozenLake* de la librería *Gymnasium*, en su versión determinista. El entorno consiste en una cuadrícula de cuatro por cuatro casillas en la que un agente debe desplazarse desde la casilla inicial hasta la casilla meta evitando cuatro agujeros. Los elementos del problema se definen de la siguiente manera. El estado corresponde a la casilla ocupada por el agente y toma valores entre 0 y 15. Las acciones son cuatro: desplazarse a la izquierda, hacia abajo, a la derecha o hacia arriba. La recompensa es igual a 1 al alcanzar la meta e igual a 0 en cualquier otra transición, incluida la caída en un agujero. La política es la regla que asigna una acción a cada estado.

7.1 Entrenamiento del agente

El agente se entrenó con el algoritmo *Q-learning* (Watkins y Dayan, 1992), que mantiene una tabla de 16 por 4 valores en la que cada celda estima la recompensa futura acumulada de ejecutar una acción determinada en un estado determinado. Esta tabla se actualiza tras cada transición combinando la recompensa inmediata con el mejor valor estimado del estado siguiente, ponderado por un factor de descuento de 0,95. Dado que la recompensa solo se recibe al alcanzar la meta, la exploración resulta indispensable, y se implementó mediante una estrategia que inicia con decisiones casi aleatorias y va

reduciendo progresivamente la proporción de exploración a medida que el agente acumula experiencia (Figura 12).




Figura 12. Curva de aprendizaje del agente y decaimiento del parámetro de exploración.

Después de 2.000 episodios de entrenamiento, el agente aprendió una política que resuelve el entorno en la totalidad de los 100 episodios de evaluación ejecutados sin exploración. La política aprendida consiste en descender por la primera columna hasta la tercera fila, avanzar hacia la derecha y descender nuevamente hasta alcanzar la meta, evitando los cuatro agujeros. Los valores finales de la tabla aumentan de forma progresiva a medida que las casillas se acercan a la meta, lo que refleja que el agente aprendió no solo qué acción tomar en cada casilla sino también cuán cerca está de obtener la recompensa.

7.2 Reflexión sobre RLHF

El agente descrito aprende porque el entorno le entrega una recompensa numérica inequívoca: alcanzar la meta vale 1 y cualquier otra transición vale 0. Al entrenar un modelo generativo de lenguaje esa señal no existe, ya que no hay una función matemática que determine si una respuesta es útil, veraz o apropiada. El aprendizaje por refuerzo con retroalimentación humana, conocido como RLHF, resuelve esta dificultad sustituyendo la recompensa definida por diseño por una recompensa aprendida a partir de juicios humanos (Christiano et al., 2017; Ouyang et al., 2022).

El procedimiento consta de tres fases. En la primera se recogen comparaciones en las que personas ordenan por preferencia varias respuestas producidas ante un mismo estímulo. En la segunda se entrena, con esas comparaciones, un modelo de recompensa que aprende a puntuar respuestas de forma similar a como lo haría un evaluador humano. En la tercera el modelo generativo se optimiza por refuerzo contra ese modelo de recompensa. La correspondencia con el ejercicio desarrollado es directa: el estado es el contexto de la conversación, la acción es la respuesta que el modelo produce, la política es el propio modelo generativo y la recompensa es la puntuación asignada por el modelo entrenado sobre preferencias humanas. Cambian la escala y la naturaleza de la señal, no los principios.

De esta correspondencia se desprende también la limitación central de la técnica. Un agente de Q-learning cuya recompensa esté mal definida aprenderá a explotar esa definición defectuosa en lugar de resolver la tarea propuesta. De la misma manera, un modelo de lenguaje optimizado contra un modelo de

recompensa imperfecto aprenderá a producir respuestas que ese modelo puntúa alto, que no necesariamente coinciden con las que un evaluador humano preferiría. La política aprendida no puede ser mejor que la recompensa que la guía.

8. Comentarios sobre los resultados

Los resultados obtenidos en los dos problemas supervisados permiten formular tres observaciones de carácter general. La primera es que la superioridad de los métodos de ensamble, claramente verificada en el problema de regresión, no se traslada automáticamente al problema de clasificación cuando las clases están desbalanceadas. El random forest fue un 23,7 % mejor que el árbol en regresión, pero en clasificación redujo la exactitud del grupo1 del 80 % al 44 %. La razón es que la métrica que el algoritmo minimiza durante el entrenamiento no coincide con el objetivo real del análisis cuando una categoría concentra el 91 % de los datos.

La segunda observación es que la elección de la métrica de evaluación condiciona por completo la conclusión. En este trabajo el modelo con mayor exactitud global es una máquina de vector soporte con kernel de base radial y C igual a 100, que no acierta ningún caso del grupo3, mientras que el modelo con mayor exactitud balanceada es el mismo algoritmo con C igual a 0,01, cuya exactitud global es de apenas 0,418. Definir qué se entiende por buen desempeño antes de comparar modelos resulta, por tanto, tan importante como la selección del algoritmo.

La tercera observación es que los procedimientos no supervisados aportaron información que los supervisados no entregaron. El Isolation Forest identificó el 77,8 % de las viviendas del grupo3 sin utilizar el precio como entrada, justamente la categoría que ningún clasificador logró predecir de manera consistente. Esto sugiere que, para el segmento de viviendas de precio muy alto, un enfoque de detección de casos excepcionales resulta más apropiado que uno de clasificación.

La Tabla 11 reúne el desempeño de todos los modelos desarrollados en el trabajo.

Tabla 11. Resumen consolidado de los modelos desarrollados.

Problema	Modelo	Métrica principal	Valor
Regresión	<i>XGBoost</i>	RMSE	24.304,6
Regresión	Red neuronal (MLP)	RMSE	27.236,3
Regresión	<i>Random forest</i>	RMSE	29.615,4
Regresión	Árbol podado	RMSE	37.226,8
Regresión	Árbol sin podar	RMSE	38.816,5
Clasificación	SVM kernel lineal	Exactitud balanceada	0,768
Clasificación	Árbol con ponderación	Exactitud balanceada	0,698
Clasificación	SVM kernel RBF	Exactitud balanceada	0,619
Clasificación	Árbol de decisión	Exactitud balanceada	0,580
Clasificación	<i>XGBoost</i>	Exactitud balanceada	0,579
Clasificación	<i>Random forest</i>	Exactitud balanceada	0,476

Problema	Modelo	Métrica principal	Valor
Agrupamiento	<i>K-means</i> con K = 3	Índice de silueta	0,111
Anomalías	<i>Isolation Forest</i>	Viviendas señaladas	30 de 1.460
Refuerzo	<i>Q-learning</i>	Episodios resueltos	100 de 100

Conclusiones

El conjunto de datos permitió comparar cinco modelos de regresión y seis configuraciones de clasificación para un mismo problema. En cuanto a la regresión, el modelo de *gradient boosting* obtuvo el mejor desempeño con un RMSE de 24.304,6 dólares, equivalente al 13,4 % del precio promedio de las viviendas evaluadas, seguido por la red neuronal multicapa y en el tercer lugar, *random forest*. El árbol de decisión individual resultó ser el modelo más débil, y su error nulo sobre el conjunto de entrenamiento frente a un error de 38.816,5 dólares sobre el conjunto de prueba constituye una ilustración directa del sobreajuste, característico de este modelo.

En lo que respecta a la clasificación, el desbalance de las categorías determinó los resultados. Con 9 viviendas en el grupo3 sobre un total de 1.460, ninguno de los modelos alcanzó un desempeño confiable para esa categoría. La ponderación de clases solo consiguió mejorarlo a costa de reducir el acierto en los demás grupos. Evidentemente, la recomendación, para trabajos o análisis posteriores, es redefinir los límites de los rangos o tratar el segmento de precio alto mediante detección de casos excepcionales en lugar de clasificación.

Los procedimientos con modelos no supervisados mostraron que las características físicas de las viviendas estructuran los datos según un eje de tamaño y configuración que coincide con los rangos de precio únicamente en el segmento económico. El *Isolation Forest*, por su parte, identificó las viviendas de precio excepcional sin utilizar el precio como variable de entrada, lo que valida la utilidad de este enfoque para el segmento que la clasificación no logró modelar. Finalmente, el ejercicio de aprendizaje por refuerzo permitió verificar la convergencia de un agente sencillo y establecer la correspondencia conceptual entre sus componentes y los del procedimiento de alineación de modelos generativos.

El trabajo presenta tres limitaciones que es importante señalar como conclusión. Las cifras de referencia del enunciado, presentadas en el documento con las instrucciones de la actividad, se obtuvieron en el lenguaje R con una semilla aleatoria y un preprocesamiento no documentados, situación que solo permite hacer una comparación cualitativa y no una reproducción exacta de dichos resultados. El índice de silueta indica una estructura de conglomerados débil, de modo que la segmentación obtenida debe entenderse como exploratoria. Y el tamaño del grupo3 impide cualquier conclusión estadísticamente sustentada sobre las viviendas de precio superior a 500.000 dólares, con independencia del algoritmo utilizado.

Bibliografía

- Baum, E. B. y Haussler, D. (1989). What size net gives valid generalization? *Neural Computation*, 1(1), 151-160.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.

- Breiman, L., Friedman, J., Olshen, R. y Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794.
- Christiano, P., Leike, J., Brown, T., Martic, M., Legg, S. y Amodei, D. (2017). Deep reinforcement learning from human preferences. *Advances in Neural Information Processing Systems*, 30.
- Cortes, C. y Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
- De Cock, D. (2011). Ames, Iowa: Alternative to the Boston housing data as an end of semester regression project. *Journal of Statistics Education*, 19(3). <https://jse.amstat.org/v19n3/decock.pdf>
- Friedman, J. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189-1232.
- Haykin, S. (2009). *Neural Networks and Learning Machines* (3.^a ed.). Pearson.
- Liu, F. T., Ting, K. M. y Zhou, Z. H. (2008). Isolation forest. *Eighth IEEE International Conference on Data Mining*, 413-422.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P. et al. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O. et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Rousseeuw, P. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.
- Watkins, C. y Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3), 279-292.